3090에서 다시 재봤더니, SD가 오히려 느려졌다

W05 측정 정리 · 박지호 (하드웨어/측정 담당) · 2026-10-28 측정

> **한 줄 요약** — 준하 님 W04 맥북 실험을 **하드웨어만 RTX 3090으로 바꿔** 똑같이 돌렸더니, speculative decoding(SD)이 **12개 조건 전부 느려졌다 (0.56~0.90배)**. 원인은 GPU가 아니라 **CPU가 GPU에 명령을 보내는 속도**였다.

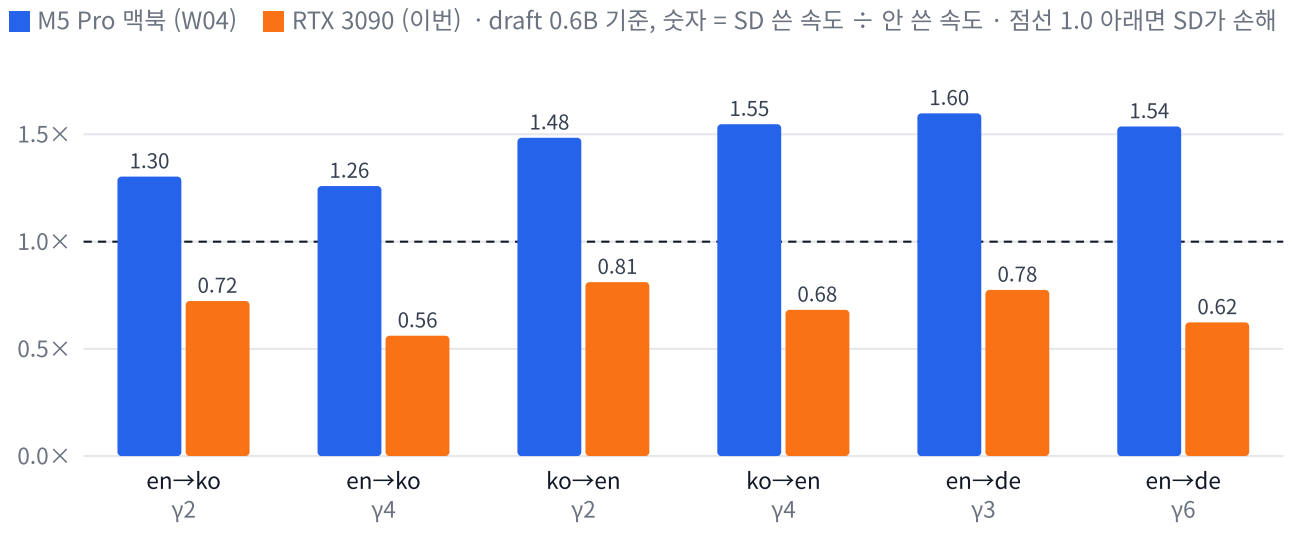
1. 뭘 했나

W04에서 준하 님이 M5 Pro 맥북으로 잰 실험을 **그대로** 다른 기기에서 다시 쟀다. 바꾼 건 하드웨어 하나뿐이다.

그대로 둔 것	바꾼 것
모델 (target Qwen3-8B, draft 0.6B·1.7B, bf16) · FLORES 같은 12문장 · greedy · batch 1 · γ 값 · 코드(`lang.py`) · torch 2.14.1 / transformers 5.18.0	M5 Pro 맥북 → **RTX 3090** (vast.ai에서 대여, 약 $1) 코드는 맥 전용(MPS)이던 부분만 GPU(CUDA)에서도 돌게 고침. 측정 방식은 동일

3090 서버 사양: GPU 메모리 실효 대역폭 843 GB/s(직접 잼), CPU는 Intel Xeon E5-2673 v4 2.3 GHz (2016년 서버용, 다른 사용자와 공유).

2. 결과 — 맥북에선 빨라졌는데, 3090에선 느려졌다



1.7B draft도 같은 모양 (맥북 1.26~1.47배 → 3090 0.68~0.90배). 측정은 안정적이었다: 같은 블록 앞뒤 속도 차이 최대 6%, 재측정 없음.

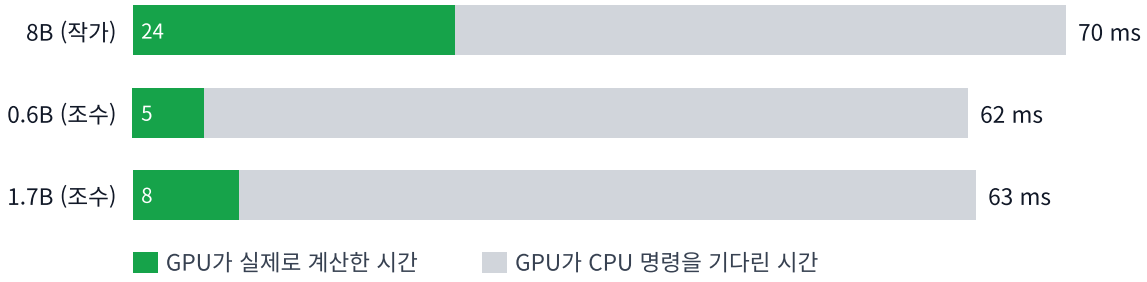
이상한 점이 하나 더 있었다.

	M5 Pro	RTX 3090
8B가 한 토큰 쓰는 시간	67 ms	**69 ms (거의 같음)**
메모리 대역폭	최대 307 GB/s (공칭)	843 GB/s (실측)
c = 조수(0.6B) 1토큰 시간 ÷ 작가(8B) 1토큰 시간	0.19	**0.75**

메모리가 3배 가까이 빠른데 속도는 같고, 조수(0.6B)가 작가(8B)와 거의 같은 시간이 걸렸다. 조수가 작가만큼 느리면 SD는 손해일 수밖에 없다.

3. 왜? — GPU는 일하는 시간보다 기다리는 시간이 더 길었다

서버가 켜져 있을 때 추가로 쟀다: 한 토큰을 만드는 동안 **GPU가 실제로 계산한 시간**과 **CPU가 GPU에 보낸 명령(커널) 수**.



모델	층 수	한 토큰 시간	GPU 실제 계산	CPU가 보낸 명령 수
Qwen3-8B (작가)	36	69.5 ms	24.0 ms (35%)	2,038개
Qwen3-0.6B (조수)	28	62.2 ms	5.3 ms (8%)	1,590개
Qwen3-1.7B (조수)	28	62.8 ms	7.9 ms (13%)	1,590개

진단은 GPU 사용률을 같이 기록하느라 조수 쪽이 약 10 ms 느리게 나왔다. c는 별도 비용 측정값(0.75 / 0.77)을 쓴다.

> **비유: 주방장과 웨이터**
> 주방장(GPU)은 엄청 빠른데, 주문서를 전하는 웨이터(CPU)가 느리다. 한 토큰마다 주문서를 **약 2,000장 한 장씩** 건네야 해서(한 장에 약 35 µs) 주방장은 대부분 기다린다.
> 주문서 장수는 요리 크기가 아니라 **코스 수(층 수)**에 비례한다. 0.6B와 1.7B는 둘 다 28층이라 장수가 같고, 그래서 크기가 3배 다른데도 걸리는 시간이 같다.

숫자로 확인

· c ≈ 층 수 비 = 28 ÷ 36 = **0.78** → 실측 c = **0.75** (0.6B), **0.77** (1.7B)

· GPU 계산 시간만 놓고 보면 c = 5.3 ÷ 24.0 = **0.22** → 원래 예측했던 값과 같다. **GPU 자체는 예상대로 움직였고, CPU가 그걸 덮어버렸다.**

· CPU 스레드 수를 20 → 13 → 4 → 1로 바꿔도 시간이 그대로 (69.3~69.5 ms) → CPU를 남과 나눠 써서 생긴 문제가 아니라, **CPU 하나가 명령을 순서대로 내보내는 속도** 문제.

4. 그래서 알게 된 것

- **"모델이 작다 ≠ 빠르다"의 실제 사례.** 0.6B는 8B보다 가중치가 14배 작은데, 이 서버에선 한 토큰 시간이 25%밖에 안 줄었다 (c = 0.75). 시간을 정한 건 크기가 아니라 층 수였다.
- **SD가 이득인지는 "GPU 계산 대비 CPU 명령 전달 비용"에 달려 있다.** 전달 비용이 클수록 c가 층 수 비(0.78)로 올라가고 SD는 손해. 맥북은 반대로 메모리 읽기가 병목이라 c가 작고(0.19) SD가 이득이었다.
- **팀 비용 공식은 다른 기기에서도 맞았다.** speedup ≈ τ ÷ (γ·c + r)에 3090에서 잰 c·r을 넣으면 12개 조건 모두 실측 신뢰구간 안 (최대 차이 0.03). 수락률(τ, α)은 맥북과 거의 같았다 → 하드웨어는 수락률이 아니라 **비용(c, r)**을 바꾼다.

측정 전에 적어 둔 예측	결과
P1. 3090에선 c가 커진다 (0.22~0.33)	방향은 **맞음**, 크기는 **틀림** (0.75). CPU 오버헤드를 4~8 ms로 봤는데 실제 약 45 ms
P2. speedup이 맥북보다 같거나 작다	**맞음** — 아예 1 아래로
P3. 작은 γ가 더 유리해진다	**맞음** — 모든 조건에서 작은 γ가 더 빠름
P4. 1.7B가 0.6B보다 더 손해	**틀림** — 둘 다 28층이라 c가 같고, 더 잘 맞히는 1.7B가 오히려 유리

5. 조심할 점

- **"3090에서는 SD가 안 된다"로 읽으면 안 된다.** 이건 "CPU가 느린 서버 + HF transformers 기본 실행 방식"의 결과다. 서버 1대, 1회 측정.
- 맥북과 3090은 GPU·CPU·소프트웨어가 전부 다르다. "CPU가 원인"은 3090 안에서의 진단으로 뒷받침되지만, **CPU만 바꾼 비교는 아직 없다.**

6. 다음에 할 것

- **CPU만 빠른 3090으로 같은 측정** (예: Ryzen 7 5800X 서버, 약 $0.3). c가 0.75에서 0.22 쪽으로 내려가면 "CPU가 원인" 확정.
- **GPU 클럭 조절** (공지 5번 Compute / Memory sweep). 학교 3090에선 금지(다른 팀 오염)라 빌린 GPU에서만. 권한이 되는지부터 확인 (스크립트에 확인 기능 있음).
- **명령 전달을 줄인 실행 방식** (llama.cpp CUDA — 팀 공통 기준선, 또는 CUDA Graph)으로 같은 3090에서 다시 재기.

→ 셋이 모이면 **"CPU 속도 × GPU 연산 × 메모리 대역폭"** 중 어디에서 SD 이득이 생기고 사라지는지 표로 답할 수 있다 (공지 10번 ⑥ "Hardware가 바뀌면 어떻게 되는가").

자세한 숫자·조건(공지 7번 항목 전부): `w05-3090/W05-3090-보고서.md` · 원자료: `result_3090_1028_0809.tar.gz`, `result_3090_diag_1028_0839.tar.gz` · 재현: `w05-3090/순서.md` (vast.ai에서 `bash run_3090.sh` 한 줄)